

何沐天

目标岗位：机器学习/数据工程实习生

邮箱: mhe3@scu.edu | 电话: 15081157255 | 所在地: 美国圣何塞 (海外在读) | 实习时间: 6-9 月

领英: www.linkedin.com/in/mutian-he | Github: github.com/austin10231 | 个人网站: www.mutianhe.com

个人简介

机器学习与数据工程方向硕士生，具备构建端到端机器学习系统与数据管道的实践经验。熟悉多模态学习、信息检索与监督学习方法，能够从非结构化数据中提取特征、构建模型并进行效果评估（如 Recall@K、ROC-AUC）。具备将模型结果转化为可解释分析与业务决策支持的能力，关注模型性能与系统可扩展性的平衡。

教育背景

圣塔克拉拉大学(Santa Clara University) | 利维商学院 US 前 60 美国 加州圣塔克拉拉
信息系统硕士 (Master of Science in Information Systems) GPA 3.7 2025.01 -2026.12
主要课程: Python 数据分析、云计算、数据库管理系统、机器学习、深度学习、NLP
格拉斯哥大学 (University of Glasgow) | 计算机科学学院 QS 前 100 英国 格拉斯哥
计算机科学学士 (Bachelor of Science in Computer Science) GPA 3.6 2021.09 -2024.6
主要课程: 数据结构与算法、数据库系统、软件工程、人机交互

个人项目

银行营销订阅预测 (机器学习) — 2026 | Pandas, Scikit-Learn, SMOTE, SHAP | [Github](#)

- 构建完整端到端机器学习分类流程 (Logistic Regression、Decision Tree、Random Forest、XGBoost)，采用 Stratified 10 折交叉验证与 GridSearchCV 调参，在独立测试集上实现 ROC-AUC 0.80。
- 针对严重类别不平衡问题 (约 1:9)，通过 SMOTE 过采样与概率阈值优化策略，显著提升少数类客户 (高价值潜在订阅客户) 的召回率。
- 引入 SHAP 进行模型可解释性分析，量化特征对预测结果的贡献，识别影响客户订阅行为的关键驱动因素。

多模态内容搜索系统 (多模态机器学习) — 2026 | PyTorch, CLIP, FAISS | [Live Demo](#) | [Github](#)

- 基于 CLIP 构建多模态语义检索系统，实现文本驱动图像搜索，将图文映射至共享 embedding 空间进行相似度匹配。
- 设计端到端检索 pipeline，涵盖数据预处理、批量图像 embedding 生成、向量索引构建与 Top-K 相似度检索，支持高效语义搜索。
- 引入 FAISS 实现近似最近邻 (ANN) 搜索，显著降低大规模图像检索延迟，相较暴力搜索提升系统可扩展性。
- 构建 Recall@1/5/10 与 Median Rank 评估体系，量化检索性能，验证模型在文本-图像匹配任务中的有效性。

股票市场实时流式数据架构 (数据工程) — 2026 | AWS (S3, Glue, Athena), SQL, Kafka, ETL | [Github](#)

- 基于 Apache Kafka 与 AWS EC2 设计并实现端到端实时股票数据流式处理架构。
- 使用 Python 构建 Producer 与 Consumer，实现模拟实时市场数据采集与消费。
- 将流式数据持久化至 Amazon S3，并结合 AWS Glue Data Catalog 进行自动化 Schema 管理。
- 通过 Amazon Athena 实现基于 SQL 的无服务器大规模数据查询与分析。

风险变化预警系统 (NLP + LLM) — 2026 | Python, AWS, LLM/NLP | [Live Demo](#) | [Github](#)

- 基于 BeautifulSoup + AWS Textract + LLM (Bedrock) 实现对 SEC 10-K 风险披露 (Item 1A) 的自动提取与结构化建模。
- 构建非结构化 (HTML/PDF) 到结构化风险数据的处理流程，支持后续分析与建模。
- 设计跨年份风险对齐与比对方法，识别新增、删除及修改风险项。
- 构建 LLM Agent 对风险进行多维度评估 (影响/概率/紧急性)，生成结构化分析报告。

技术栈

编程语言: Python、SQL (MySQL、SQLite、PostgreSQL)、Java

数据工程: Apache Kafka、Apache Airflow、ETL/ELT 数据管道、流式数据架构、数据建模

机器学习 / 深度学习: Scikit-learn, 特征工程, 交叉验证 (K-Fold) 与超参数调优, SMOTE, SHAP, 模型评估 (ROC-AUC、F1、Recall@K), 监督与非监督学习模型, 多模态学习 (CLIP、Embedding、Transformer)

云平台与数据平台: AWS (EC2、S3、Glue、Athena、RDS、Lambda)、数据湖架构